

UNIVERSIDAD DEL VALLE DE GUATEMALA

DATA SCIENCE - 40

Erick Marroquin



Laboratorio 3. Deep Learning Avances

Ihan Marroquin - 23108

Diego Patzan - 23525

GUATEMALA, 09 de agosto del 2026

Se analizaron 22 observaciones Sentinel-2 L2A de los lagos Atitlán y Amatitlán para reconocer cambios temporales y espaciales en una señal estimada de cianobacteria, sin descargar escenas satelitales completas. Los resultados son una herramienta de vigilancia: ayudan a decidir dónde conviene muestrear, pero no sustituyen un análisis de laboratorio ni permiten afirmar que el agua es tóxica.

Amatitlán presentó la señal más intensa y extendida: su promedio del periodo fue 57.80 en la escala 0-100 y, en promedio, 59.19 % del agua válida superó el umbral Cya 20. Atitlán tuvo un promedio de 6.49 y una extensión alta media de 5.86 %.

Lago	Promedio	Mediana	Fecha máxima	Máximo	Área alta media
Amatitlán	57.80	91.03	2026-04-13	98.90	59.19 %
Atitlán	6.49	2.56	2025-07-17	49.62	5.86 %

A partir de estos mismos datos, la Parte 2 entrenó modelos de clasificación (Regresión Logística, Random Forest y XGBoost) para identificar píxeles con alta presencia de cianobacteria. XGBoost alcanzó un F1 de 0.971 en evaluación mezclada y de 0.965 en validación espacial por bloques, pero la capacidad de generalizar de un lago a otro es baja: un modelo entrenado en un solo lago no debería usarse en el otro sin recalibrar el punto de corte, porque la tasa base de floración difiere fuertemente entre Amatitlán (46.85 % de píxeles positivos) y Atitlán (0.82 %).

Parte 1. Análisis geoespacial

1. Datos y método

La conexión con Sentinel-2 se dejó disponible mediante openEO (<https://openeo.dataspace.copernicus.eu>). Para producir el informe se consultó también el catálogo STAC de Planetary Computer (<https://planetarycomputer.microsoft.com/api/stac/v1>, colección sentinel-2-l2a), seleccionando el satélite oficial de cada fecha. Se leyeron únicamente las bandas B02, B03, B04, B08 y la capa de calidad SCL dentro de los rectángulos de los lagos, a una resolución de 120 metros. No se guardan contraseñas ni se descargan escenas completas.

La capa SCL retiró nubes, cirros, sombras, nieve, saturación y ausencia de datos. NDWI se utilizó para conservar únicamente el agua. La estimación Cya siguió el script Se2WaQ: $Cya = 115530.31 \times ((B03 \times B04) / B02)^{2.38}$. Para resumir y comparar se empleó la escala visual 0-100 del mismo script; Cya 20 se tomó como corte de señal alta.

Las correlaciones se calcularon con una muestra reproducible de hasta 3,000 píxeles por lago y fecha. Se informan Pearson y Spearman, aunque la interpretación principal usa Spearman porque las relaciones no son necesariamente lineales. En total se procesaron 22 observaciones (11 de Amatitlán y 11 de Atitlán), cada una con su escena satelital, porcentaje de nubosidad y número de píxeles de agua válidos trazados.

2. Evolución temporal




Figura 1. Promedio de Cya y porcentaje del agua válida con $Cya \geq 20$.

Amatitlán alternó periodos bajos con aumentos abruptos. El mayor promedio apareció el 2026-04-13, con 98.90; la mayor extensión se observó el 2026-04-28, cuando el 100.00 % del agua válida superó el umbral. Los episodios de abril de 2025 y de marzo a junio de 2026 no fueron puntos aislados: afectaron una fracción amplia del lago.

Atitlán se mantuvo bajo en la mayoría de observaciones. Su excepción fue el 2025-07-17, con promedio 49.62 y 51.68 % de área alta. Esa fecha conservó 1,128 píxeles válidos, frente a más de 6,000 en la mayoría de fechas, por lo que el tamaño del episodio debe confirmarse con muestreo o con otra imagen cercana.

3. Distribución espacial en Amatitlán




Figura 2. Distribución de la señal Cya en las once fechas de Amatitlán.

Los periodos altos abarcan los dos cuerpos principales y el estrechamiento que los conecta. La intensidad cambia entre fechas, pero la señal no permanece restringida a una sola orilla. En enero de 2025, noviembre de 2025 y febrero de 2026 predominan valores bajos; en abril de 2025 y entre marzo y junio de 2026 dominan valores altos.




Figura 2b. Persistencia de valores altos (% de fechas con $C_{ya} \geq 20$) — Amatitlán.

4. Distribución espacial en Atitlán




Figura 3. Distribución de la señal Cya en las once fechas de Atitlán.

Atitlán presenta una señal más tenue y menos persistente. Las observaciones de abril y mayo de 2026 muestran aumentos moderados; julio de 2025 destaca por encima del resto, aunque su cobertura válida es menor. Los focos costeros sirven para priorizar recorridos de campo, pero los fragmentos aislados fuera del contorno principal no se interpretan como parte del lago.




Figura 3b. Persistencia de valores altos (% de fechas con $Cya \geq 20$) — Atitlán.

5. Persistencia y cambio espacial

La persistencia separa los episodios ocasionales de las zonas que reaparecen. En Amatitlán una parte considerable del lago supera el umbral en varias fechas, con mayor recurrencia en el cuerpo sur. Atitlán permanece oscuro en casi toda su superficie: la señal alta aparece en menos fechas y en áreas más localizadas.




Figura 4a. Cambio de Cya entre la primera y la última observación — Amatitlán.




Figura 4b. Cambio de Cya entre la primera y la última observación — Atitlán.

6. Relación con NDVI y NDWI




Figura 5. Relaciones por píxel en Amatitlán (NDVI y NDWI vs. Cya).




Figura 6. Relaciones por píxel en Atitlán (NDVI y NDWI vs. Cya).

Lago	Índice	n	Pearson r	Spearman rho
Amatitlán	NDVI	9,090	0.462	0.536
Amatitlán	NDWI	9,090	-0.350	-0.420
Atitlán	NDVI	31,128	-0.024	-0.341
Atitlán	NDWI	31,128	-0.438	-0.906

Cya disminuye cuando NDWI aumenta: la relación de Spearman es moderada en Amatitlán y fuerte en Atitlán. Esto puede reflejar la forma en que las bandas entran a ambos índices, además de diferencias reales en el agua; no debe leerse como una causa ambiental. La relación con NDVI cambia entre lagos: positiva moderada en Amatitlán y negativa débil a moderada en Atitlán.

7. Comparación y contexto ambiental

La diferencia principal no está solo en el pico máximo. Amatitlán combina intensidad, extensión y persistencia; Atitlán combina una base baja con episodios más aislados. Por eso el promedio temporal de Amatitlán es casi nueve veces el de Atitlán y el área alta media es aproximadamente diez veces mayor.

Como contexto, AMSA trabaja en la cuenca de Amatitlán sobre descargas de aguas residuales y desechos sólidos. AMSCLAE identifica para Atitlán aportes de aguas residuales, escorrentía, erosión y nutrientes. Estos factores son explicaciones plausibles para una proliferación, pero el presente laboratorio no midió temperatura, nutrientes ni caudales; por ello no se asigna una causa específica a cada fecha.

Lago	Temporada	Fechas	Cya promedio	Área alta media
Amatitlán	Lluviosa	1	91.03	99.88 %
Amatitlán	Seca	10	54.48	55.12 %
Atitlán	Lluviosa	3	19.08	18.69 %
Atitlán	Seca	8	1.77	1.05 %

La aparente diferencia estacional no es concluyente. Amatitlán tiene una sola fecha lluviosa y el promedio lluvioso de Atitlán está dominado por el episodio de julio de 2025. Se necesitarían observaciones regulares durante varios años para hablar de estacionalidad.

8. Análisis exploratorio adicional




Figura 7. Distribución de Cya por fecha — Amatitlán.




Figura 8. Distribución de Cya por fecha — Atitlán.

Las distribuciones confirman que algunos promedios altos corresponden a casi todo el lago y no únicamente a valores extremos. En Amatitlán varias fechas se concentran cerca de 100; en Atitlán la mayor parte de los píxeles permanece cerca de cero, con colas altas en fechas puntuales.

Conclusiones (Parte 1)

1. Amatitlán presentó la señal Cya más intensa, extensa y persistente del periodo.
2. Atitlán mantuvo valores bajos en la mayoría de fechas, con un episodio crítico el 17 de julio de 2025 que requiere confirmación por su menor cobertura válida.

3. El 28 de abril de 2026 fue la fecha de mayor extensión en Amatitlán: toda el área de agua válida superó Cya 20.
4. La relación negativa con NDWI fue consistente en ambos lagos, pero describe una asociación espectral y no una causa de proliferación.
5. La comparación espacial mostró que intensidad, extensión y persistencia aportan información distinta; ninguna debe reemplazarse por un único promedio.
6. Los resultados orientan vigilancia y muestreo. No determinan toxicidad ni aptitud del agua para consumo o recreación.

Limitaciones (Parte 1)

Las fechas son irregulares, la resolución de análisis es 120 m y la máscara de agua es espectral. Algunas observaciones conservan menos agua válida. La fórmula Se2WaQ es empírica y no fue calibrada con muestras de estos lagos durante las fechas estudiadas.

Reproducibilidad

El notebook ejecutado contiene las salidas principales. El módulo `src/analisis_completo.py` consulta las 22 fechas, aplica las máscaras, calcula métricas, genera mapas y reconstruye las tablas. El flujo openEO se mantiene en `src/procesamiento_geoespacial.py`.

Parte 2. Modelos de Machine Learning

La Parte 1 dejó, para 11 fechas de Atitlán y 11 de Amatitlán, los valores de NDVI, NDWI y densidad estimada de cianobacteria (Cya). Esta segunda parte convierte esa información en una tabla donde cada fila es un píxel de agua con su posición, su fecha y sus valores espectrales, y la usa para entrenar modelos que identifiquen zonas con alta presencia de cianobacteria.

construir_dataset() lee dos cubos por lago, ambos en EPSG:32615 a 120 m, el mismo sistema en metros que usan los bloques espaciales de la validación espacial: cubo_<lago>.npz (NDVI, NDWI, Cya y la máscara de validez, generado por src/analisis_completo.py) y cubo_nir_<lago>.npz (la banda B08, de descargar_nir()). B08 es la única banda del conjunto que no entra en la fórmula de Cya, así que es la única reflectancia usable como predictora.

9. Preparación de los datos para Machine Learning

construir_dataset() recorre cada lago y cada fecha oficial, lee los rasters de Cya, NDVI, NDWI y las bandas de reflectancia, y apila los píxeles en una sola tabla. Las coordenadas salen del centro de cada píxel usando la transformación afín del GeoTIFF, así que cada observación conserva su ubicación real. Se leyeron 468,468 píxeles, de los cuales quedaron 83,980 válidos (384,488 descartados).

Descarte	Motivo
Píxeles con SCL de nube, sombra, cirro, nieve o saturación	La Parte 1 ya los marcó; llegan con valido = False o como NoData
Reflectancia no positiva en B02, B03, B04 o B08	La fórmula de Cya divide entre B02; un valor no positivo la vuelve inestable
cya NaN o no finito	Sin valor de respuesta no hay observación
cya negativo	La densidad de células no puede ser negativa; indica división inestable
ndwi < 0	El píxel no es agua: está fuera del lago o sobre la orilla

El filtro por NDWI es el que define "dentro del lago". Es el mismo criterio que usó el script Se2WaQ en la Parte 1, así que la máscara del dataset y la de los mapas coinciden.

Lago	Observaciones
Amatitlán	9,090
Atitlán	74,890
Total	83,980

Análisis exploratorio (dataset a nivel de píxel)




Figura 9. Distribución de las variables principales ($\log_{10}$ Cya, NDVI, NDWI, B08).




Figura 10. Matriz de correlación de Spearman entre variables.




Figura 11. Distribución espacial de las observaciones ($\log_{10}$ de Cya) por lago.

Sobre B08 hay que ser explícito: su correlación de Spearman con Cya es 0.93. No es fuga, porque B08 no entra en la fórmula, pero conviene entender de dónde sale ese número. NIR y el índice de Cya responden al mismo fenómeno físico (la biomasa flotante), y además la máscara de agua exige $NDWI \geq 0$, lo que equivale a $B03 \geq B08$ y acota el rango de la banda. Con una predictora tan informativa las métricas de evaluación van a salir altas; la prueba real está en la validación espacial y en la generalización entre lagos.

Decisiones tomadas: la unidad de análisis es el píxel, no el lago (promediar por fecha dejaría solo 22 observaciones); Cya se guarda cruda y en log, aplicando el corte sobre la escala original para conservar su significado físico; y no se imputan faltantes, porque un píxel sin dato es uno que el satélite no midió.

10. Construcción de la variable respuesta

Se2WaQ entrega la densidad estimada de cianobacteria en 10^3 células/mL. El corte no se elige por conveniencia estadística sino por el umbral sanitario: la OMS sitúa en 100,000 células/mL el punto donde el riesgo en aguas recreativas deja de ser bajo y pasa a moderado (Alert Level 2). En las unidades del raster son 100 unidades, el mismo valor que la Parte 1 usó para los mapas. Cya se recorta a $[0, 100]$, que es la escala visual de Se2WaQ; el recorte cae justo sobre el umbral, así que $cya \geq 100$ sigue marcando la clase correcta, aunque se pierde la magnitud por encima del corte. La consecuencia es que Cya sirve para clasificar, no para regresión.

Umbral aplicado: $100.0 \times 10^3 \text{ cel/mL} = 100,000 \text{ cel/mL}$. Clase positiva: 5.80 % del total, con una razón negativos:positivos de 16.2:1. El desbalance es marcado; se usan F1 y ROC-AUC en lugar de Accuracy.

Lago	n	Altas	% altas
Amatitlán	9,090	4,259	46.85 %
Atitlán	74,890	613	0.82 %

El reparto por lago es lo más llamativo: 46.85 % de píxeles positivos en Amatitlán frente a 0.82 % en Atitlán. Por fecha, Amatitlán alterna entre fechas casi limpias (0.5–1.9 %) y fechas de floración masiva (78–98 %), lo que sugiere que el mes y la época van a pesar en los modelos.

Criterio	Umbral	% altas
OMS vigilancia (20 000 cel/mL)	20.00	8.48 %
OMS riesgo moderado (100 000 cel/mL)	100.00	5.80 %
Percentil 75 observado	4.24	25.00 %
Percentil 90 observado	14.60	10.00 %

Sobre el desbalance: Accuracy deja de servir (predecir siempre "sin floración" acierta el 90 % sin detectar nada); el entrenamiento se sesga hacia la clase mayoritaria, lo que se corrige con `class_weight="balanced"` y `scale_pos_weight`; y la comparación se hace con Recall, F1 y ROC-AUC, porque en contexto ambiental el error caro es el falso negativo: no avisar de una floración tóxica expone a bañistas y pescadores.

11. Selección y construcción de variables predictoras

Como la respuesta es $cya \geq \text{umbral}$, quedan prohibidas `cya`, `cya_log` y las tres bandas de la fórmula (B02, B03, B04). Un caso menos evidente: NDVI usa B04 y NDWI usa B03; no son la respuesta, pero comparten insumo con ella. De ahí los dos conjuntos, estricto (sin ellos) y amplio (con ellos), que permiten medir cuánto del desempeño viene de esa dependencia en vez de asumirlo.

Conjunto estricto: B08, mes, dia_del_anio, epoca_lluviosa, es_amatitlan, x, y, dist_centro. Conjunto amplio: los mismos ocho más `ndvi` y `ndwi`.

Variable	Tipo	Justificación
B08	Banda espectral	Reflectancia en infrarrojo cercano; el agua clara la absorbe, delata biomasa flotante
mes	Temporal	Captura la estacionalidad de las floraciones
dia_del_anio	Temporal	Versión continua del mes; evita el corte artificial entre diciembre y enero
epoca_lluviosa	Temporal	Mayo a octubre; la escorrentía arrastra nutrientes agrícolas y aguas residuales
es_amatitlan	Categórica	Distingue los dos lagos, que difieren en profundidad, altitud y carga de nutrientes
x, y	Espacial	Posición en metros (EPSG:32615), las mismas coordenadas de los bloques
dist_centro	Espacial	Distancia al centroide del lago; aproxima cercanía a la orilla y desembocaduras
ndvi, ndwi	Índice (solo conjunto amplio)	Comparten insumo con la fórmula de Cya (B03, B04)

12. Construcción de modelos

Se usa el conjunto estricto de predictoras (sin NDVI/NDWI) y una división 70/30 estratificada por la clase. Los tres modelos usan `class_weight` balanceado o `scale_pos_weight` por el desbalance descrito. Los hiperparámetros se ajustan con GridSearchCV (`cv=3`, `scoring F1`, porque la clase positiva es minoritaria y F1 castiga tanto los falsos positivos como los falsos negativos).

Modelo	Mejores hiperparámetros
Regresión Logística	C = 1
Random Forest	<code>max_depth = None</code> , <code>n_estimators = 200</code>
XGBoost	<code>learning_rate = 0.1</code> , <code>max_depth = 6</code> , <code>n_estimators = 400</code>

13. Evaluación de modelos

Modelo	Accuracy	Precision	Recall	F1	ROC-AUC
Regresión Logística	0.897	0.349	0.898	0.502	0.965
Random Forest	0.996	0.945	0.995	0.969	1.000
XGBoost	0.997	0.950	0.992	0.971	1.000




Figura 12. Matrices de confusión — Regresión Logística, Random Forest y XGBoost.

Un falso positivo (marcar alta presencia donde no la hay) cuesta un cierre o aviso innecesario. Un falso negativo (no detectar una zona con alta presencia) deja a bañistas y pescadores expuestos a una toxina. El segundo error es más grave, así que Recall pesa más que Accuracy o Precision para elegir el modelo, con F1 como resumen porque también penaliza el exceso de falsas alarmas.

Regresión Logística tiene el Recall más bajo y una Precision muy pobre (0.35): genera demasiadas falsas alarmas. Random Forest y XGBoost quedan prácticamente empatados y muy por encima en las cinco métricas. Se usa XGBoost como mejor modelo para el resto del análisis, por tener el F1 más alto. Este desempeño casi perfecto tiene una causa concreta: B08 correlaciona 0.93 con Cya. No es fuga —B08 no entra en la fórmula—, pero es una señal casi determinística; la validación espacial y entre lagos que siguen son la prueba real de qué tanto generaliza el modelo.

14. Validación espacial

Antes de fijar el tamaño de bloque se revisa cuántos bloques de 1 km × 1 km caen dentro de cada lago y cuántas observaciones tiene cada uno. Las coordenadas ya están en EPSG:32615, así que la cuadrícula se arma directamente sobre x/y.




Figura 13. Bloques espaciales de 1 km × 1 km — Amatitlán (42 bloques) y Atitlán (172 bloques).

Lago	N.º de bloques	Obs. promedio	Obs. mínima	Obs. máxima
Amatitlán	42	216.4	1	792

Atitlán	172	435.4	1	842	
Modelo	F1 aleatoria	ROC-AUC aleatoria	F1 espacial	ROC-AUC espacial	Δ F1
Regresión Logística	0.502	0.965	0.536	0.971	+0.034
Random Forest	0.969	1.000	0.964	1.000	-0.005
XGBoost	0.971	1.000	0.965	1.000	-0.006

La caída es pequeña (F1 y ROC-AUC bajan centésimas, no décimas) porque B08 es un predictor por píxel: su relación con Cya no depende de qué bloque vecino esté en entrenamiento. Aun así, la validación espacial es la estimación más realista, porque en un despliegue real el modelo siempre predice sobre zonas que no vio durante el entrenamiento. La validación aleatoria, al mezclar píxeles de bloques adyacentes entre train y test, deja pasar autocorrelación espacial que infla ligeramente el desempeño.

15. Generalización entre lagos

Se retira es_atitlan de las predictoras porque sería constante dentro de cada lago, y se entrena en un lago para evaluar en el otro.

Experimento	n entrenamiento	n evaluación	F1	Recall	ROC-AUC	Δ F1 vs. mismo lago
Mismo lago (train/test mezclados)	-	-	0.971	0.992	1.000	0.000
Entrena = Atitlán / evalúa = Amatitlán	74,890	9,090	0.113	0.060	0.820	-0.858
Entrena = Amatitlán / evalúa = Atitlán	9,090	74,890	0.203	1.000	0.995	-0.768

Un modelo entrenado en un lago no generaliza al otro, y falla de formas distintas: entrenado en Atitlán (apenas 0.82 % de positivos), el modelo aprende que "casi nunca hay alta presencia" y no detecta casi ninguna floración real en Amatitlán (F1 = 0.11, Recall = 0.06). Entrenado en Amatitlán (46.85 % de positivos), el modelo dispara alertas por todos lados y las mantiene incluso en Atitlán, donde la clase positiva es minoritaria: detecta todo (Recall = 1.00), pero con precisión muy baja (F1 = 0.20).

El ROC-AUC (0.82 y 0.995) sugiere que el modelo sí ordena bien las zonas de riesgo relativo en ambos casos, pero el punto de corte aprendido en un lago no sirve para el otro. La causa es la tasa base: Amatitlán es más somero, más urbanizado y recibe más carga de nutrientes que Atitlán, así que "alta presencia" significa proporciones de área completamente distintas en cada lago. Un modelo entrenado en un solo lago no debería usarse en el otro sin recalibrar el umbral de decisión.

16. Interpretación y explicabilidad del modelo

Se usa XGBoost, el mejor modelo de la evaluación anterior.

Variable	Importancia (ganancia)
B08	0.602
epoca_lluviosa	0.214
es_amatitlan	0.110
y	0.037
dia_del_anio	0.014
mes	0.010
x	0.008
dist_centro	0.005




Figura 14. Importancia global de las predictoras (XGBoost).

Variable	SHAP medio (abs.)	Correlación valor–SHAP
B08	7.824	+0.604
y	4.207	-0.873
dia_del_anio	1.347	-0.383
x	0.820	+0.568
dist_centro	0.676	+0.571
es_amatitlan	0.611	+0.727
epoca_lluviosa	0.587	+0.916
mes	0.496	-0.495




Figura 15. Resumen SHAP: impacto de cada predictora en la salida del modelo.

B08 domina la importancia global y el SHAP: su correlación valor–SHAP es positiva (+0.60), es decir, más reflectancia en infrarrojo cercano empuja la predicción hacia "alta presencia", coincidiendo con lo esperado (el agua clara absorbe el NIR casi por completo). epoca_lluviosa tiene la segunda correlación más fuerte y positiva (+0.92): la escorrentía de mayo a octubre aporta nutrientes que favorecen la floración. es_amatitlan también correlaciona positivo (+0.73), confirmando que ese lago concentra la señal. La variable y (posición norte-sur) tiene una correlación fuerte y negativa (-0.87): las zonas más al sur del área de estudio —donde cae Amatitlán— tienden a predicción más alta, la misma señal geográfica que es_amatitlan vista desde la coordenada en vez de la etiqueta del lago.

17. Mapas predictivos

Se generó la probabilidad promedio de alta presencia por píxel (agregando todas las fechas disponibles), junto a un mapa de aciertos/errores espaciales por píxel, para cada lago.

Atitlán

Comparación con la Parte 1: el mapa de Cya original (izquierda/arriba) frente al mapa predictivo del modelo (derecha/abajo), para verificar que la probabilidad alta coincide con las zonas donde ya se veían floraciones.




Figura 16. Mapa de Cya original (Parte 1) — Atitlán, las once fechas.




Figura 17. Mapa predictivo — Atitlán (probabilidad de alta presencia).




Figura 18. Errores espaciales — Atitlán.

Amatitlán

La misma comparación para Amatitlán: mapa de Cya original de la Parte 1 y mapa predictivo del modelo.




Figura 19. Mapa de Cya original (Parte 1) — Amatitlán, las once fechas.




Figura 20. Mapa predictivo — Amatitlán (probabilidad de alta presencia).




Figura 21. Errores espaciales — Amatitlán.

Lago	% aciertos	% falsos positivos	% falsos negativos
Atitlán	100.0 %	0.0 %	0.0 %
Amatitlán	98.84 %	1.05 %	0.11 %

En Amatitlán el modelo acierta el 98.84 % de las observaciones, con 1.05 % de falsos positivos y solo 0.11 % de falsos negativos: el error que más importa ambientalmente es el que menos comete. En Atitlán el acierto es prácticamente total, esperable dado que solo el 0.82 % de sus píxeles son positivos. El mapa predictivo reproduce la misma geografía que el mapa de Cya de la Parte 1: la probabilidad alta se concentra en las mismas zonas donde ya se veían las floraciones persistentes, sin focos nuevos sin respaldo en los datos originales. El mapa de errores confirma esto: los falsos positivos y negativos aparecen dispersos y aislados, no agrupados en una región particular del lago.

18. Análisis y conclusiones (Parte 2)

¿Tiene el modelo capacidad suficiente para apoyar el monitoreo? Con validación aleatoria y espacial dentro del mismo lago, sí: F1 y ROC-AUC se mantienen altos y estables. Pero esa capacidad depende de una sola banda (B08) altamente correlacionada con la respuesta, y la generalización entre lagos muestra que el modelo no transfiere sin recalibrar el umbral. Como herramienta de apoyo dentro de un mismo lago ya monitoreado, es útil; como herramienta genérica para cualquier cuerpo de agua, no está lista.

Limitaciones principales

- Dependencia de una sola banda espectral: B08 concentra casi toda la importancia; el modelo aprendió poco de las variables espaciales y temporales por sí solas.
- Desbalance extremo y distinto por lago (46.85 % vs. 0.82 % de positivos), causa directa de la falla en generalización.
- Solo 22 fechas en total y sin cobertura sistemática de todas las estaciones del año en ambos lagos.
- Resolución de 120 m: agrupa varios metros de orilla en un solo píxel, perdiendo variabilidad fina cerca de las desembocaduras.
- Un solo satélite y sin datos in situ que confirmen la fórmula Se2WaQ contra muestreos físicos reales.

Qué ayudaría a mejorar el modelo

- Precipitación y temperatura por fecha, para separar el efecto de la época lluviosa de la carga de nutrientes real.
- Muestreos físicos de cianobacteria para calibrar el umbral y validar Se2WaQ.
- Más fechas por lago, sobre todo en Amatitlán, para que la validación espacial tenga más bloques con densidad de observaciones comparable a Atitlán.

Sobre la dimensión espacial: ignorar la autocorrelación espacial infla el desempeño, aunque aquí poco porque B08 es un predictor de píxel. El caso extremo de generalización entre lagos —dos lagos vecinos, mismo sensor, misma fórmula— muestra que el modelo de uno no sirve para el otro sin ajustar el punto de corte a la tasa base de cada lugar. Cualquier modelo geoespacial que ignore esto va a sobreestimar su propia capacidad de generalizar a zonas o lagos nuevos.

Reproducibilidad

El procesamiento completo de la Parte 1 está en `src/analisis_completo.py`; el flujo openEO se conserva en `src/procesamiento_geoespacial.py`. La Parte 2 se implementa en `src/ml_cianobacteria.py` (preparación del dataset, ingeniería de características) y `src/modelos_cianobacteria.py` (entrenamiento, validación espacial, generalización entre lagos, explicabilidad y mapas predictivos). Todas las tablas y figuras se regeneran desde las fechas oficiales sin guardar credenciales.

Referencias

- Copernicus Data Space Ecosystem. Getting started with the openEO Python client.
- Microsoft Planetary Computer. Sentinel-2 Level-2A collection.
- Sentinel Hub Custom Scripts. Se2WaQ - Sentinel-2 Water Quality Script.
- AMSA. División de Reingeniería Industrial y Agroindustrial.
- AMSCLAE. Informe anual de calidad ambiental 2024.
- WHO (2003). Guidelines for safe recreational water environments. Volume 1.
- WHO (2021). Guidelines on recreational water quality. Volume 1.
- Chorus, I. & Welch, M. (eds.) (2021). Toxic Cyanobacteria in Water, 2ª ed.
- Potes, M. et al. (2018). Se2WaQ, Sentinel Hub Custom Scripts.